

Курсова работа

Практикум алгоритми за бизнес анализи за напреднали, зимен семестър 2024/2025

Изготвил: Боряна Баджева, факултетен номер 0EB4100523

Въведение

Обработката на липсващи данни е критичен аспект от науката за данни, тъй като влияе върху качеството на прогнозите и производителността на моделите. Липсващите данни могат да възникнат по различни причини, които се категоризират в три механизма: структурни недостатъци, случайни събития и специфични причини.

Един от начините за разбиране на липсващите данни, е чрез достигане до причината за тяхната липсва и периода на пораждаването ѝ. Към структурни недостатъци се причисляват, когато компонент от предиктор е бил пропуснат и липсва в множеството. Обикновено, този тип липсващи стойности са едни от най-лесните за разрешаване ако необходимия компонент е идентифициран [1].

Случайните събития, които водят до липса на стойности, могат да се разделят на два вида- Напълно случайно липсващи данни (MCAR) и Липсващи данни по случайност (MAR). При MCAR, вероятността за липсващ резултат е еднаква за всички точки от данни т.е. липсващите стойности са независими от данните. За MAR- вероятността за липсващи резултати не е еднаква за всички точки от данни. При този сценарий, вероятността за липсващ резултат зависи от наблюдаваните данни, но не и от ненаблюдаваните данни [2].

Могат да съществуват и специфични причини, които да доведат до липсата на данни (Not Missing at Random – NMAR). Този тип се срещат по-често при клинични проучвания, в които пациентите се измерват периодично през определен период от време. Например, пациентът може да отпадне от изследването поради страничен ефект от лечението или смърт [2].

Една широко използвана стратегия за справяне с липсващите данни е еднократно присвояване (импутация), при която липсващите стойности се заменят с подходящо изчислена стойност. Ползността на методите за импутация се различават съществено в зависимост от това дали целта на анализа е извод/обяснение или прогнозиране. Всяка цел има различни приоритети, допустими отклонения и дисперсии [3].

Подходът към обработката на липсващи данни варира в зависимост от това дали целта е извод/обяснение или прогнозно моделиране. При причинно-следствените изводи или обяснителните анализи, основната цел е да се осигури валиден статистически извод чрез осигуряване на безпристрастна оценка на параметрите и точно представяне на неопределеността. Избраният метод за обработка на липсващи данни трябва да бъде съобразен с основните допускания за механизма на липсващите данни, за да се избегне внасянето на отклонения или подвеждащи заключения. При прогнозното моделиране, основната цел е да се оптимизира работата на модела, а не да се осигурят безпристрастни оценки на параметрите. Това често включва минимизиране на грешката при прогнозиране [3].

Еднократното присвояване замества липсващите стойности с една оценена стойност, като създава пълен набор от данни за анализ. Често срещан подход е заместването на липсващите стойности със средната стойност, медианата или модата на наблюдаваните данни. Този метод е лесен за прилагане и е полезен за проучвателен анализ, но има недостатъци. Той намалява дисперсията, изкривява връзките между променливите (Haitovsky, 1968) и подценява стандартните грешки, като увеличава риска от грешки. Освен това, не успява да запази зависимостите между фийчърите при множества с повече дименсии. (Nguyen, 2025).


Методология

Разгледаното множество от данни Liver Disorders съдържа 6 независими променливи и зависима променлива, наименована „Health condition“. В първите 6 колони са независими променливи- 1 mean corpuscular volume (mcv), 2 alkaline phosphatase (alkphos), 3 alamine aminotransferase (sgpt), 4 aspartate aminotransferase (sgot), 5 gamma-glutamyl transpeptidase (gammagt) , 6 number of half-pint equivalents of alcoholic

beveragesdrunk per day (drinks). Седмата колона съдържа информация за медицинското състояние на човека- 1=Здрав и 2=Болен, това е нашата зависима променлива.

В първия етап от анализа, не се наблюдават липсващи стойности в множеството. Прилагат се няколко модела с различни похвати за разделение на тренировъчно и тестово подмножество, с цел установяване кой от всички класифицира наблюденията с най-висока точност. Използваните модели включват Logistic regression с kFold разделение и K-nearest neighbor с kFold разделение. Получените резултати се анализират с помощта на Confusion matrix и classification report и се избира най-добър модел.

Във втория етап на анализа, по изкуствен начин и на случаен принцип, са изтрити 20% от данните, съдържащи се в колоните на независимите променливи. Прилагат се четири подхода за запълване на липсващите стойности- изтриване на целия ред с липсващи стойности, заместване с медианата на съответната колона, заместването на липсващите стойности със средната стойност на избрана колона и групиране, и заместването на липсващите стойности с медианата на избрана колона и групиране. Целта е да се открие при кой от четирите начина, резултатът се доближава максимално до най-високия резултат от първия етап, като се използва същия модел, с който е бил постигнат.



Графика 1: Визуално представяне на проведените експерименти, параметрите

при всеки от тях и получените резултати.

Източник: Изготвено от автора

Анализирайки графика 1 установяваме, че най-добри резултати за двата класа и оценка на тренировъчното подмножество, са постигнати при **logreg = LogisticRegression(solver='liblinear', max_iter=4200); kf = KFold(n_splits=17, shuffle=True, random_state=72)**. Това са моделът и параметрите, които ще бъдат използвани във втората част на анализа.

Подходът, използвам при всеки от четирите начина за заместване е липсващите стойности, е графично представен чрез схемите:

Фигура 2: Стъпки, приложени при изграждане на алгоритъм за изтриване на редове с липсващи стойности

Източник: Изготвено от автора

Откриваме редове с
NaN стойности

Определяме независими
променливи и зависима
променлива

Дефинираме модела и начинът на
разделение между test и train
подмножество

Оценяваме представянето на модела
с помощта на confusion matrix и
classification report

```
indexNaN = np.nonzero(pd.isnull(data_liver_NAN_drop.values).any(1))[0]
```

```
X = data_liver_NAN_drop_values.iloc[:,6]
y = data_liver_NAN_drop_values.iloc[:,6]
```

```
logreg = LogisticRegression(solver='liblinear', max_iter=4200)
kf = KFold(n_splits=17, shuffle=True, random_state=72)
```

```
print('Score on test set:', score_test)
print("\nConfusion Matrix for test set:")
print(metrics.classification_report(predicted_y, y_test,
                                     digits=4))
```

Изтриването на целите редове, където са налични липсващи стойности, е един от най-бързите начини за справяне с тях. В използваното множество, редовете се редуцират от 345 на 76 след прилагането му.

Фигура 3: Стъпки, приложени при изграждане на

алгоритъм за заместване на липсващи стойности

Определяме imputer и го прилагаме за
всички колони без зависимата
променлива

Определяме независими
променливи и зависима
променлива

Дефинираме модела и начинът на
разделение между test и train
подмножество

Оценяваме представянето на модела
с помощта на confusion matrix и
classification report

```
columns_to_impute = data_liver_NAN_mean.columns.difference(['Health
condition'])
imputer = SimpleImputer(strategy='median')
data_liver_NAN_mean[columns_to_impute] =
imputer.fit_transform(data_liver_NAN_mean[columns_to_impute])
```

```
X = data_liver_NAN_mean.iloc[:,6]
y = data_liver_NAN_mean.iloc[:,6]
```

```
logreg = LogisticRegression(solver='liblinear', max_iter=4200)
kf = KFold(n_splits=17, shuffle=True, random_state=72)
```

```
print('Score on test set:', score_test)
print("\nConfusion Matrix for test set:")
print(metrics.classification_report(predicted_y, y_test,
                                     digits=4))
```

Източник: Изготвено от автора

Фигура 3 представя процеса, който е преминал при заместване на липсващите стойности със средната стойност на колоната. Стойностите за всяка колона са както следва: 'MCV' - 90, 'Alkphos'- 67.5, 'SGPT'- 26 , 'SGOT'- 23, 'Gammagt'- 25 и 'Drinks per day'- 3.


Фигура 4: Стъпки, приложени при изграждане на алгоритъм за заместване на липсващи стойности

Определяме метод за попълване, на база групиране по колона "Health condition"

Определяме независими променливи и зависима променлива

Дефинираме модела и начинът на разделение между test и train подмножество

Оценяваме представянето на модела с помощта на confusion matrix и classification report



Източник: Изготвено от автора

Фигура 4 последва последователните стъпки, преминали с цел запълване на стойностите чрез заместването със средната стойност на избрана колона и групиране. Избрана е колоната на зависимата променлива и се изчислява средната стойност на база данните в нея. Изчислени са : 'MCV' – 89.6211 при стойност 2 на зависимата променлива и 90.6396 при стойност 1 , 'Alkphos'- 69.9091 при стойност 2 и 72.5046 при стойност 1, 'SGPT'- 28.5882 при 2 и 31.2358 при стойност 1 , 'SGOT'- 26.0888 при 2 и 23.3727 при стойност 1, 'Gammagt'- 44.6933 при стойност 2 и 30.4159 при стойност 1, 'Drinks per day'- 3.30063 при стойност 2 и 3.77917 при стойност 1.

Фигура 5: Стъпки, приложени при изграждане на алгоритъм за заместване на липсващи стойности

Определяме метод за попълване, на база медианата от колоната за групиране "Health condition"

Определяме независими променливи и зависима променлива

Дефинираме модела и начинът на разделение между test и train подмножество

Оценяваме представянето на модела с помощта на confusion matrix и classification report

```
columns_to_fill = data_liver_NAN_drop.columns.difference(['Health condition'])
for col in columns_to_fill:
    data_liver_NAN_drop_median[col] = data_liver_NAN_drop.groupby('Health condition')[col].transform('median')
```

```
X = data_liver_NAN_drop_median.iloc[:,6]
y = data_liver_NAN_drop_median.iloc[:,6]
```

```
logreg = LogisticRegression(solver='liblinear', max_iter=4200)
kf = KFold(n_splits=17, shuffle=True, random_state=72)
```

```
print('Score on test set:', score_test)
print("\nConfusion Matrix for test set:")
print(metrics.classification_report(predicted_y, y_test, digits=4))
```

Източник: Изготвено от автора


Фигура 5 онаглеждава предприетите стъпки за запълване на стойностите чрез заместването с медианата на избрана колона и групиране. В случая е избрана колоната на зависимата променлива и след изчисляване на нейната медиана, в празните пространства се записват числата 'MCV' – 90.6396, 'Alkphos'- 69.9091, 'SGPT'- 28.5882 , 'SGOT'- 26.0888, 'Gammagt'- 44.6933 и 'Drinks per day'- 3.30063.

Резултати

Графика 1 представя Recall, получен за двата класа при всеки от експериментите, както и оригиналните данни. Тъй като при прилагане на метода за изтриване на целите редове се губи съществена част от данните и е възможно да наруши даден тренд в множеството, то неговия Recall не е включен. Получените стойности за него са [1.0000, 1.0000], както и оценка от 1.00. Сравнявайки ги с резултатите при оригиналното множество, те са значително по-високи. Това само потвърждава, че методът с изтриване не е препоръчително да се прилага в множества, където липсват повече от 20% от данните.

Графика 1:

Сравнение между получения Recall за Class 1 и Class 2 при упоменатите експерименти в легендата



Източник: Изготвено от автора

В оранжев цвят са представени резултатите, получени при оригиналното множество. При Class 1, експериментите с групиране и взимане средна стойност на конкретна колона и групиране и взимане медиана на конкретна колона, дават един и същ резултат от 0.8333. При Class 2, оригиналното множество има Recall от 0.8462, а експеримент 4) най-много се доближава до това число с резултат 0.8571. Въпреки че не е най-високия Recall за Class 2, целта на анализа е да открие експеримент, при който данните ще се доближат до оригиналните такива.

Таблица 1: Изчислена оценка

за всеки от експериментите за тестовото подмножество и цялото множество

Experiment	Score
Original data- test set	0.9047
Original data- full dataset	0.6985
Experiment 1 ¹ - test set	1.00
Experiment 1- full dataset	0.7368
Experiment 2 ² - test set	0.85
Experiment 2- full dataset	0.6579
Experiment 3 ³ - test set	0.85
Experiment 3- full dataset	0.6782
Experiment 4 ⁴ - test set	0.85
Experiment 4- full dataset	0.6666

Източник: Изготвено от автора

¹ Експеримент 1 – при него се изтриват всички редове, в които се наблюдават липсващи стойности.

² Експеримент 2- при него липсващите стойности са заместени с медианата на съответната колона.

³ Експеримент 3- при него се използва подхода за заместване на стойностите със средната стойност на избрана колона и групиране.

⁴ Експеримент 4- липсващите стойности са заместени с медианата на избрана колона и групиране.

Таблица 1 потвърждава, че резултатите от експеримент 3 и експеримент 4 са най-близки до търсените от нас стойности- разликата между двете оценки е 0,0116.

В обобщение, експеримент 4 постига сходни резултати до оригиналните при Recall на двата класа. В следствие на което използвания метод за запълване на липсващи стойности, модел и параметри в него, е най-подходящ за разглежданото множество в проекта.

Дискусия

В настоящия проект бяха изследвани различни методи за справяне с липсващите данни, като основният фокус беше върху единичната импутация с използване на средна стойност, медиана и мода. Алтернативните методи, като множествена импутация или модели, базирани на машинно обучение (например KNN или Random Forest), биха могли да предложат по-точни оценки, като отчитат зависимостите в данните. В бъдещи изследвания е препоръчително да се разгледат и тези методи, особено в контекста на predictive modeling⁵, където запазването на структурните е от съществено значение.

Използваният процент контролирано изтриване на данните е 20%, което ограничи прилагането на единия от подходите, а именно изтриване на редовете с липси. Тъй като използваното множество от данни има само 375 реда с наблюдения, при изтриване броят им се редуцира значително- до 76, което ограничава възможностите за по-нататъшните действие.

В други изследвания е възможно да се наложи прилага PCA⁶ или LDA⁷ метод при наличието на голям брой независими променливи. С тяхното използване се намалява „шумът“ и може да се съкрати времето за обработка при огромен обем от данни. В текущата ситуация това не бе необходимо, тъй като обемът от наблюдения и независими променливи е малък.

⁵ Процес, при който се използват статистически и машинно-обучителни техники, за да се предскажат бъдещи резултати на базата на исторически данни. Една от целите е да се идентифициране на зависимости в данните, който могат да бъдат използвани за прогнозиране на неизвестни стойности.

⁶ Анализ на главните компоненти (Principle component analyses) е техника за редуциране, която се използва за трансформиране на мултидименсионни данни в такива с по-малък размер. Проверяваме значимостта на всеки от компонентите и изчисляваме общата дисперсия. Целта е да се запази възможно най-висока дисперсия с малък брой независими променливи. Обикновено, първите компоненти от множеството са най-значими [4].

⁷ Линеен дискриминантен анализ (Linear discriminant analysis) е метод, при който обозначените класове в зависимата променлива се използват, за да се раздели пространството на предикторите в региона като всички региони имат линейни граници. Моделът предсказва, че всички наблюдения от даден регион принадлежат към един и същ клас на зависимата променлива [4].

На практика, постигнатите резултати в този проект могат да се приложат директно при бъдещо анализиране на множество със сходни характеристики. След като вече са разгледани Логистична регресия (LR) и моделът на Най-близкия съсед(kNN), и са постигнати заключения при сравняване на техните представяния, то тези знания може да директно да се приложат в работата. Въпреки това е препоръчително да се гледа критично на резултатите и да се изследват начини за тяхното подобряване.

Заключение

Настоящия курсов проект разглежда представянето на няколко от най-известните начини за единична импутация при липсващи данни. Разгледано бе множеството Liver disorders, което по своето естество не съдържа липсващи данни. Откриваме, че моделът Логистична регресия с kFold разделение, предсказва по-добре класа на наблюденията, отколкото K-nearest neighbor с kFold разделение. Поради това, анализът в част две на проекта е извършен с модела Логистична регресия и същите параметри, с които е постигнато най-доброто разделение. По изкуствен начин бяха изтрети 20% от данните в множеството, а след това направени 4 експеримента за откриване на този, който най-много ще се доближи до резултатите при оригиналното множество. Установено е, че Експеримент 4 отговаря на търсените критерии- при него е използван подходът на заместване с медианата на дадена колона и групиране. Възможно надграждане на анализа включва изследване на различни параметри и извършването на допълнителни експерименти с модели като Support Vector machines с линейно и нелинейно ядро.

Използвана литература

[1]. Feature Engineering and Selection: A Practical Approach for Predictive Models: Chapter 8

[2]. Little, R, and D Rubin. 2014. Statistical Analysis with Missing Data. John Wiley & Sons.

[3]. A Guide on Data Analysis, Mike Nguyen 2025-01-31, Chapter 11

[4]. Dimension Reduction in Data Science, Garzon, M., Chapter 2, Chapter 4

- Използвано множество от данни-
<https://archive.ics.uci.edu/dataset/60/liver+disorders>